

支持向量机研究进展

顾亚祥¹ 丁世飞^{1,2}

(中国矿业大学计算机科学与技术学院 徐州 221116)¹

(中国科学院计算技术研究所智能信息处理重点实验室 北京 100080)²

摘 要 基于统计学习理论的支持向量机(Support vector machines, SVM)以其优秀的学习能力受到广泛的关注。但传统支持向量机在处理大规模二次规划问题时会训练时间长、效率低下等问题。对 SVM 训练算法的最新研究成果进行了综述,对主要算法进行了比较深入的分析和比较,指出了各自的优点及其存在的问题,并且着重介绍了目前研究的新进展——模糊 SVM 和粒度 SVM。接着论述了 SVM 主要的两方面应用——分类和回归。最后给出了今后 SVM 研究方向的预见。

关键词 支持向量机, 训练算法, 模糊支持向量机, 粒度支持向量机

中图法分类号 TP181 文献标识码 A

Advances of Support Vector Machines(SVM)

GU Ya-xiang¹ DING Shi-fei^{1,2}

(School of Computer Science and Technology, China University of Mining and Technology, Xuzhou 221116, China)¹

(Key Laboratory of Intelligent Information Processing, Institute of Computing Technology, Chinese Academy of Sciences, Beijing 100080, China)²

Abstract Support vector machines(SVM) are widespread attended for its excellent ability to learn, that are based on statistical learning theory. But in dealing with large-scale quadratic programming(QP) problem, traditional SVM will take too long time of training time, and has low efficiency and so on. This paper made a summarize of the new progress in the SVM training of algorithm, and made analysis and comparison on main algorithm, pointed out the advantages and disadvantages of them, focused on new progress in the current study——Fuzzy Support Vector Machine and Granular Support Vector Machine. Then the two mainly applications——classification and regression of SVM were discussed. Finally, the article gave the future research directions on SVM prediction.

Keywords Support vector machine, Training algorithm, Fuzzy SVM, Granular SVM

支持向量机是 Vapnik 等人于 1995 年首先提出的^[1],它是基于 VC 维理论和结构风险最小化原则的学习机器。它在解决小样本、非线性和高维模式识别问题中表现出许多特有的优势,并在一定程度上克服了“维数灾难”和“过学习”等传统困难,再加上它具有坚实的理论基础,简单明了的数学模型,使得支持向量机从提出以来受到广泛的关注,并取得了长足的发展。

支持向量机的训练算法归结为求解一个受约束的 QP 问题。对于小规模 of QP 问题,它体现出了十分优秀的学习能力,但当将其应用到大规模的 QP 问题时,就会表现出训练速度慢、算法复杂、效率低下等问题。现在主要的训练算法都是将原有大规模的 QP 问题分解成一系列小的 QP 问题。但是如何进行分解以及选择合适的工作集是这些算法面临的主要问题,并且这也是各个算法优劣的表现所在。另外一些算法主要是增加函数项、变量或系数等方法使公式变形,使其具有某一方面的优势,或者有一定应用范围。

目前研究的大规模问题训练算法并不能够彻底解决所面

临的问题,因此在原有算法上进行合理的改进或者研究新的训练算法势在必行。本文对主要的训练算法以及 SVM 扩展算法进行了综述,并在此基础上对未来研究的方向进行了展望。

1 SVM 基本理论

支持向量机最初是在模式识别中提出的。假定训练样本集合 $(x_i, y_i), i=1, \dots, l, x_i \in R^n, y_i \in \{-1, +1\}$, 可以被超平面 $x \cdot w + b = 0$ 无错误地分开,并且离超平面最近的向量离超平面的距离是最大的,则这个超平面称为最优超平面^[1]。而 SVM 的主要思想是通过某种事先选择的非线性映射将输入向量 x 映射到一个高维特征空间 Z ,并在这个空间中构造最优超平面^[2,3]。但是如何求解得到这个最优超平面以及如何处理高维空间中经常遇到的维数灾难问题?针对第一个问题,主要将训练 SVM 算法归结成一个 QP 问题,并且该问题的解由下面的拉格朗日函数的鞍点给出:

$$L(w, b, \alpha) = \frac{1}{2} w^2 - \sum_{i=1}^l \alpha_i \{y_i [x_i \cdot w] - b - 1\}$$

到稿日期:2010-03-14 返修日期:2010-06-21 本文受江苏省自然科学基金项目(BK2009093),国家自然科学基金项目(60975039)资助。

顾亚祥(1987—),男,硕士生,主要研究方向为数据挖掘、支持向量机, E-mail: guyaxiang@yahoo.com.cn; 丁世飞(1963—),男,教授,博士生导师,主要研究方向为机器学习与数据挖掘、人工智能与模式识别等。

并且问题的解在鞍点处满足对 w 和 b 的偏导为 0 然后将该 QP 问题转化为相应的对偶问题即:

$$\max_{\alpha} Q(\alpha) = -\frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j \alpha_i \alpha_j \langle x_i \circ x_j \rangle + \sum_{i=1}^l \alpha_i$$

$$s. t. \sum_{i=1}^l y_i \alpha_i = 0, i = 1, \dots, l \quad 0 \leq \alpha_i \leq 1, i = 1, \dots, l$$

解得决策函数为:

$$f(x) = \text{sgn}(\langle w \circ x \rangle + b) = \text{sgn}(\sum_{i=1}^l \alpha_i^* y_i \langle x \circ x_i \rangle + b^*)$$

从对偶表达式中, 可以看出只有一部分 $\alpha_i > 0$ 称它对应的训练点为支持向量^[4]。

如何处理高维特征空间中维数灾难? 研究发现在特征空间中构造最优超平面, 并不需要以显式形式来考虑特征空间, 而只需要能够计算支持向量与特征空间中向量的内积, 但是如何计算特征空间中的内积? SVM 不直接进行计算该内积, 而是用满足 Mercer 定理的核函数来代替, 如下:

$$\Phi(x) \circ \Phi(x_j) = K(x \circ x_j)$$

式中, $\Phi(\cdot)$ 是输入向量到特征空间的一个非线性映射。因此, 只要将原空间中对偶问题表达式的内积形式用核函数 $K(x \circ x_j)$ 代替, 即是特征空间中对偶问题的表达形式。

2 SVM 算法研究进展

2.1 SVM 训练算法

经过上面的讨论, 我们知道 QP 问题的解仅依赖于与支持向量对应的那些训练样本点, 但是当训练样本增大时, 就会过多占用内存, 从而导致训练时间过长和效果不佳, 因此设计适合于大量样本的算法成为 SVM 研究中的重要内容。这其中主要有:

(1) chunking 算法^[5]

Boser 和 Vapnik 首先提出的 chunking 算法的目标是通过某种迭代方式逐步排除非支持向量, 从而降低训练过程对存储器容量的要求。具体的算法是将训练集分成若干个子集, 然后任选一个子集, 运用标准的 QP 方法求解对偶问题, 得到支持向量, 保留支持向量对应的样本点, 舍去其他的样本点。然后用得到的决策函数去检验剩余的样本, 将最不满足 KKT 条件的 M 个样本与先前得到的支持向量组成新的一个块, 构成新的子 QP 问题, 直到满足某一个停机准则。如果在某一步中, 不满足 KKT 条件的样本数不足 M 个, 则将这些样本全部加入到新的 QP 问题中。显然, 这种方法有利于降低问题的复杂程度, 尤其是支持向量远远小于训练样本时。然而, 如果支持向量的数目本身就比较, 随着算法迭代次数的增多, 工作集样本也会越来越大, 算法依旧会变得十分复杂。

(2) 分解算法^[6]

Osuna 等人首先提出了分解方法, 主要思想是将训练样本分成工作集 B 和非工作集 N , 并保持大小不变。在解决每个子 QP 问题前, 从 B 中移出一个样本, 然后再从 N 中移进一个不满足 KKT 条件的样本, 然后求解关于 B 的子 QP 问题。该算法的关键是工作集的选取一定要最优, 但 Osuna 在工作集的选取中采用了随机的方法, 因此限制了算法的收敛速度。针对这个问题, Joachims^[7] 系统地改进了 Osuna 的方法, 主要体现在工作集的选择上。其基本思想是, 如果存在不满足 KKT 条件的样本, 利用最速下降法, 在最速下降方向中存在 q 个样本, 然后以这 q 个样本构成工作集, 在此工作集上

解决 QP 问题, 直到所有样本满足 KKT 条件。Joachims 的改进有助于提高算法收敛速度, 并且他利用这些方法实现了 SVM^{light}。

(3) SMO 算法^[8]

Platt 提出了分解算法的极端情形——SMO 算法; 该算法工作集中只有 2 个样本, 即将一个大的优化问题分解为一系列只含两个变量的子优化问题, 由于子优化问题只涉及两个变量, 而且应用等式约束可以将一个变量用另一个变量线性表示出来, 因此在每一步求解 QP 问题时, 不必要在迭代中求解, 只要将每一步的子问题的最优解直接用解析的方法表示出来。虽然迭代的次数增加了很多, 但由于两个变量间直接可以用解析式表示, 因此每次迭代的时间非常短, 大大缩短了训练时间。同时在工作集的选择上, 它采用了两种启发式方法进行搜索, 而不是传统的最速下降法。主要采用两个嵌套的循环: 外层循环首先遍历非边界样本, 调整不满足 KKT 条件的样本, 当所有的非边界样本满足 KKT 条件时; 再进行内层循环, 而内层循环是针对以上违反 KKT 条件的样本来选择另一个样本与它配对优化, 其选择的准则是使选择的一对样本能够对决策函数得到最大的优化步长。

SMO 算法主要耗时在最优条件的判断上和在非线性情情况下误差的重置方面, 所以应寻找最合理即计算代价最低的最优条件判别式。

SMO 算法提出后, 许多学者对它进行了有效的改进。文献^[9]提出了在内循环中每次优化 3 个变量, 因为 3 个变量的优化问题同样可以解析求解。实验表明该算法比 SMO 的训练时间更短。文献^[10]提出了一种新的停止准则, 它可以使训练速度更快。

(4) 增量学习方法

增量学习是机器学习系统在处理新增样本时, 只对原学习结果中与新样本有关的部分进行增加、修改或删除操作, 与之无关的部分则不被触及。增量训练算法的一个突出特点是 SVM 的学习是一个数据逐一加入反复优化的过程。Cauwenberghs^[11]提出了一种用于模式识别的增量式学习方法, 它考虑了增加或减少一个训练样本对拉格朗日系数和 SVM 的影响; 其缺点是当样本无限增多时, 还必须抛弃一些样本, 使其能够使用。Ralaivola^[12]提出了另一种增量式学习方法, 其思想是基于高斯核的局部特性, 只更新对学习机器输出影响最大的 Lagrange 系数, 以减少计算复杂度。Y. G. Liu^[13]把增量学习过程定义成为一个二次优化问题。另外李忠伟等^[14]也提出了一种增量式学习的 SVM 训练方法。

(5) 粒度支持向量机^[15]

粒度支持向量机是近年来兴起的一种新的训练算法, 它是由 Y. C. Tang 首先提出来的。它是以粒度计算(GrC)理论和统计学习理论为基础的一种新型学习模型。其主要思想是通过常用的粒划分方法构建粒空间获得一系列信息粒, 然后在每个信息粒上进行学习, 最后通过聚合信息粒上的信息(如数据、规则、知识、属性等)获得最终的 SVM 决策函数。这一学习机制通过数据粒化可以将一个线性不可分问题转化为一系列线性可分问题, 也就是说将一个大规模的 QP 问题, 通过粒度划分, 分解为一系列小的 QP 问题; 同时, 也使得数据的泛化性能增强, 即可在 SVM 训练中得到间隔更宽的超平面。如何进行粒度划分是粒度支持向量机研究的主要问题。目

前,主要的研究都是在原空间上进行粒度划分,主要有:基于关联规则的粒度支持向量机^[16],其基本思想是通过将径向基核函数进行麦克劳林展开,从展开式中学习关联关系,通过这些关联关系进行粒度划分,进而在各个粒上进行SV训练。基于聚类的粒度支持向量机^[17]的基本思想是通过常用的聚类方法对训练样本集进行粒度划分,然后选择包含支持向量较多的粒参与分类或回归。基于商空间的粒度支持向量机^[18]的基本思想是首先对训练样本集进行粗粒度的选择SV,去除一部分对构造最优分类超平面对无用的样本点,然后再对粗选后的样本进行细粒度的SV训练。此外还有基于树形层次结构的粒度支持向量机^[19]等。虽然在原空间上粒度划分算法的研究取得了不错的成果,但我们也发现在原空间上进行粒度划分,然后再映射到核空间会导致数据在原空间的分布与在核空间的分布不一致的问题,从而降低了算法的泛化性。

以上几种训练算法的共同点都是将一个大规模的QP问题分解为一系列小的子QP问题,最后实现对原问题的求解。不同的是对原问题的分解策略以及工作集的选取策略,这也是导致算法优劣的原因。经过上面的分析,我们也可以将chunking算法、分解算法、SMO算法、增量学习算法这4种算法看作特殊的粒度支持向量机算法,不同的是各自划分粒度的方法不一样,而且粒度的精度也不同。随着SVM训练算法的不断完善成熟,基于二次规划求解SVM问题会逐渐向实用化发展,但同时我们也发现完美地实现用二次规划求解SVM问题仍有很长的路要走。

(6) 模糊支持向量机^[20-22]

模糊SVM(FSVM)是将模糊数学和支持向量机相结合的学习方法,主要用来处理训练样本中的噪声数据。其主要的思想是:计算每个样本属于各类的隶属度,噪声数据属于该类的隶属度较低,由此来降低噪声对最优超平面的影响。模糊支持向量机中,训练数据中多了一项 s_i ,它表示样本 x_i 属于 y_i 的隶属度。其目标函数变为 $\frac{1}{2} \|w\|^2 + C \cdot \sum_{i=1}^l s_i \cdot \xi_i$,对偶形式中只是 α_i 的范围变成 $0 \leq \alpha_i \leq C \cdot s_i$ 。FSVM主要存在的问题是如何确定隶属度值,即如何确定各个样本的权重。虽然不少研究者在这方面做了很多的工作,但还没有一个可遵循的一般性准则,这其中主要有两类方法:一类是基于时间序列的度量方法,这类方法以训练样本的采集时间顺序来确定模糊隶属度,然而该方法缺乏坚实的理论依据,并且仅仅使用于序列学习的情况。另一类是基于样本空间的度量方法,其中比较有代表性的是基于KNN的模糊隶属度度量方法^[23],该方法具有较少的计算量及较强的鲁棒性。另外文献^[24, 25]提出了基于样本到类中心的距离来度量其隶属度的大小,但这可能会导致将含噪声或野值的样本与有效样本赋予相同的隶属度。文献^[26, 27]提出了一种基于密度法的FSVM,在SVM中引入样本密度模糊参数,样本密度定义为一个样本的某一邻域内样本的个数,考虑了支持向量和孤立点、噪声点两方面的因素来产生模糊参数。

此外,SVM训练算法还有Yang^[28]提出的训练SVM的几何方法,提出了“卫向量”(Guard-vector)的概念,通过卫向量构成传统的QP问题解出支持向量。张学工^[29]等提出了CSV(SVM)算法等。

2.2 SVM 的扩展算法

随着支持向量机研究的深入,人们提出了一些SVM的扩展算法。这些扩展算法主要是增加函数项、变量或系数等方法使公式变形,产生出有某一方面的优势,或者有一定应用范围的算法,如 ν -SVM^[30],广义SVM^[31](GSVM)等。 ν -SVM算法中用参数 ν 取代 C , ν 表示边界支持向量数量的上限和支持向量数量的下限,即参数 ν 可以控制支持向量的数量和误差,它具有较好的鲁棒性,容易选择。GSVM直接以优化系数和核矩阵构造出一个不等式约束的非线性优化问题,其对偶形式与标准的SVM等价,但GSVM并不是直接求解此优化问题或者其对偶形式,而是构造出若干特例,如光滑SVM、近似SVM、简化SVM等。

此外还有LS-SVM^[32,33],加权SVM^[34],PSVM^[35,36],One-class SVM^[37],WSVM^[38]等。

2.3 SVM 的应用

SVM主要运用在模式分类^[39,40],回归问题两方面^[41, 42]。其中在分类问题中,主要有线性分类和非线性分类,线性分类中又分为线性可分和线性不可分两种情况。线性不可分相对于线性可分来说,就是引入了一个松弛变量 ξ 。线性分类是在原空间中进行样本分类,而非线性分类是将向量从原空间映射到特征空间,并用核函数代替内积运算,在特征空间中进行样本分类。回归问题是通过把样本集因变量进行上下平移 ϵ ,将回归问题转化为分类问题。回归问题有线性回归和非线性回归,非线性回归是在线性回归的基础上引入两个松弛变量 ξ, ξ^* 来控制误差大小。

结束语 虽然SVM目前发展得很好,但其仍然存在一些目前无法解决的问题,比如:SVM自选参数目前尚缺乏结构化方法来实现参数的最优选择;对于具体的应用,如何选取最合适的核函数;如何彻底解决大样本时训练算法速度慢、算法复杂、运算量大等缺点。

但我们同时也应该注意到SVM的一些新进展,这主要体现在将其他学科与SVM相结合,最终达到提高SVM训练速度,降低算法复杂度和运算量的要求。比如前面提到的FSVM和粒度支持向量机,其中FSVM存在的主要问题是样本隶属度的确定,如何找到一个可遵循的一般性准则来确定隶属度将是一个长期的发展目标。粒度支持向量机目前的研究主要集中在原空间上的粒度划分,如果能够实现将粒度划分转移到核空间,那将解决原空间上粒度划分出现的一些问题,如原空间与核空间分布不一致的问题。

参 考 文 献

- [1] Vapnik V N. 统计学习理论[M]. 许建华, 张学工, 译. 北京: 电子工业出版社, 2009
- [2] Vapnik V N. The Nature of Statistical Learning Theory [M]. New York: Springer-Verlag, 1995
- [3] Cristianini N, Shawe-Taylor J. 支持向量机导论[M]. 李国正, 王猛, 等译. 北京: 电子工业出版社, 2004
- [4] 张学工. 关于统计学习理论与支持向量机[J]. 自动化学报, 2000, 26(1): 32-41
- [5] Boser B, Guyon I, Vapnik V. A training algorithm for optimal margin classifiers [C] // Proceedings of the 5th Annual ACM Workshop on Computational Learning Theory. New York: ACM Press, 1992: 144-152
- [6] Osuna E, Frenud R, Girosi F. An improved training algorithm

- for support vector machines[C] // Proceedings of IEEE Workshop on Neural Networks for Signal Processing, New York, USA, 1997; 276-285
- [7] Joachims T. Making large-scale support vector machine learning practical[M] // A. J. Smola B. Scholkopf, C. Burges, eds. Advances in Kernel Methods: Support Vector Machines, Cambridge, MA: MIT Press, 1998
- [8] Platt J. Fast training of support vector machines using sequential minimal optimization[M] // A. J. Smola B. Scholkopf, C. Burges, eds. Advances in Kernel Methods: Support Vector Machines, Cambridge, MA: MIT Press, 1998
- [9] Dai Liuling, Huang Heyan, Chen Zhaoxiong. Ternary sequential analytic optimization algorithm for SVM classifier design[J]. Asian Journal of Information Technology, 2005, 4(3): 2-8
- [10] Keerthi S S, Shevade S, Bhattacharyya C, et al. Improvements to Platt's SMO algorithm for SVM classifier design[R]. Dept. of CSA, Bangalore, India, 1999
- [11] Cauwenberghs G, Poggio T. Incremental and Decremental Support Vector Machine Learning[M] // Advances in Neural Information Processing Systems (NIPS 2000). Cambridge, MA: MIT Press, 2001
- [12] Ralaivola L, Flovenc d'Alche-Bue. Incremental Support vector machine Learning: a Local Approach[C] // Proceedings of International Conference on Neural Networks, Vienna, Austria, 2001; 322-330
- [13] Liu Yangguang, He Qingming, Chen Qi. Incremental batch learning with support vector machines[C] // Proc. of the 5th World Congress on Intelligence Control and Automation, Hangzhou, China, 2004, 2; 1857-1861
- [14] 李忠伟, 张健沛, 杨静. 基于支持向量机的增量学习算法研究[J]. 哈尔滨工程大学学报, 2005, 26(5): 643-646
- [15] Tang Yuchun, Jin Bo, Zhang Yanqing. Granular Support Vector Machines for Medical Binary Classification Problem[C] // G. B. Fogl, eds. Proceedings of the IEEE CIBIB, Piscataway, HJ: IEEE Computational Intelligence Society, 2004; 73-78
- [16] Tang Yuchun, Jin Bo, Zhang Yanqing. Granular support vector machines with association rules mining for protein homology prediction[J]. Artificial Intelligence in Medicine, 2005, 35(1): 121-134
- [17] 张鑫, 王文剑. 一种基于粒度的支持向量机学习策[J]. 计算机科学, 2008, 35(8A): 101-103, 116
- [18] 文贵华, 向君, 丁月华. 基于商空间粒度理论的大规模 SVM 分类算法[J]. 计算机应用研究, 2008, 25(8): 2299-2301
- [19] Yu Hwango, Yang Jiong, Han Jiawei, et al. Making SVMs Scalable to Large Data Sets Using Hierarchical Cluster Indexing[J]. Data Mining and Knowledge Discovery, 2005, 11(3): 100-128
- [20] Lin Chunfu, Wang Shengde. Fuzzy support vector machines[J]. IEEE Trans on Neural Network, 2002, 3(2): 464-471
- [21] Cawley G C. An empirical evaluation of the fuzzy kernel perception[J]. IEEE Trans on Neural Networks, 2007, 18(3): 935-937
- [22] Lin Chunfu, Wang Shengde. Fuzzy support vector machines with automatic membership setting[J]. StudFuzz, 2005, 177; 233-254
- [23] 郑恩辉. 基于支持向量机的代价敏感数据挖掘研究与应用[D]. 杭州: 浙江大学, 2006
- [24] Huang H P, Liu Y H. Fuzzy support vector machines for pattern recognition and data mining[J]. Incremental Journal of Fuzzy Systems, 2002, 4(3): 826-835
- [25] 张翔, 肖小玲, 徐光祐. 模糊支持向量机中隶属度的确定与分析[J]. 中国图像图形学报, 2006, 11(8): 1188-1192
- [26] 安金龙, 王正欧, 马振平. 基于密度法的模糊支持向量机[J]. 天津大学学报, 2004, 37(6): 544-548
- [27] 武方方, 赵银亮, 蒋泽飞. 基于密度聚类的支持向量机分类算法[J]. 西安交通大学学报, 2005, 39(12): 1319-1322
- [28] Yang M H, Ahuja N. A Geometric Approach to Train Support Vector Machines[C] // Proceedings of IEEE Computer Society Conference on Computer Vision and Pattern Recognition, Hilton Head, SC, USA, 2000, 1; 430-437
- [29] Kou Zhenzhen, Xu Jianhua, Zhang Xuegong, et al. An Improved Support Vector Machine Using Class-Median Vectors[C] // Proceedings of the 8th International Conference on Neural Information Processing, Shanghai, China, 2001, 2; 883-887
- [30] Kazush I I. Effects of kernel function on v2support vector machines in extreme cases[J]. IEEE Trans on Neural Networks, 2006, 17(1): 129
- [31] Huang Suyun, Lee Y J. Reduced support vector machines: a statistical theory[J]. IEEE Trans on Neural Networks, 2007, 18(1): 12-13
- [32] Anthony K, Philippe D W. Comments on pruning error minimization in least squares support vector machines[J]. IEEE Trans on Neural Network, 2007, 18(2): 606-609
- [33] Jiao Licheng, Bo Liefeng, Wang Ling. Fast sparse approximation for least squares support vector machine[J]. IEEE Trans on Neural Network, 2007, 18(3): 685-697
- [34] Wang Defeng, Daniel S Y, ERIC C T. Weighted mahalanobis distance kernels for support vector machines[J]. IEEE Trans on Neural Networks, 2007, 18(5): 1453-1462
- [35] Mangasarian O L, Wild E W. Multisurface Proximal Support Vector Machine Classification via Generalized Eigenvalues[J]. IEEE Trans on pattern analysis and machine intelligence, 2006, 28(1): 69-74
- [36] 陶晓燕, 姬红兵, 马志强. 基于样本分布不平衡的近似支持向量机[J]. 计算机科学, 2007, 34(5): 174-176
- [37] Schdkopf B, Plat J C, Shawe-Taylor J, et al. Estimating the support of a high-dimensional distribution[J]. Neural Computation, 2001, 13(7): 1443-1471
- [38] Zhang Li, Zhou Weida, Jiao Licheng. Wavelet support vector machine[J]. IEEE Trans on Systems, Man and Cybernetics, Part B, 2004, 34(1): 34-39
- [39] Doumpos M, Zopounidis C. Additive support vector machines for pattern classification[J]. IEEE Trans on Systems, Man, and Cybernetics, Part B, 2007, 37(3): 540-550
- [40] Jayadeva, Khemchandani R, Chandra S. Twin support vector machines for pattern classification[J]. IEEE Trans on Pattern Analysis and Machine Intelligence, 2007, 29(5): 905-910
- [41] Wu Zhili, LI Chunhung, Joseph K, et al. Location estimation via support vector regression[J]. IEEE Trans on Mobile Computing, 2007, 6(3): 311-321
- [42] Hao Peiyi, Chiang J H. Fuzzy regression analysis by support vector learning approach[J]. IEEE Trans on Fuzzy Systems, 2008, 16(2): 428-441